



Presentación del proyecto

Proyecto de Machine Learning: Nomadismo digital y coste de vida global

Modelado de atractivo para nómadas digitales usando variables de coste de vida, conectividad y bienestar.

1. Resumen ejecutivo

Qué problema resuelve el proyecto y qué hallazgos son accionables para negocio

Problema

Elegir destinos para nómadas digitales exige combinar coste, vivienda, conectividad, bienestar y fiscalidad. El proyecto convierte esas variables en una lógica de segmentación y priorización.

Solución analítica

Se trabajó en dos frentes: clustering de 4,742 ciudades para crear segmentos comparables y regresión para predecir el digital nomad score de países.

Valor negocio

Permite recomendar destinos, construir rankings, filtrar mercados objetivo y explicar qué variables mueven más el atractivo de un país.

Ciudades analizadas

4,742

base para segmentación

Países analizados

85

base para regresión

Clusters elegidos

4

Silhouette = 0.35

Mejor modelo

ElasticNet

mejor equilibrio

Desempeño test

RMSE 4.39

$R^2 = 0.79$

Mensajes clave


- El atractivo no depende solo del coste: **conectividad y bienestar pesan mucho.**
- Existen **segmentos de ciudades claramente diferenciados** entre low cost, premium y alternativas con menor valor real.
- El modelo final es útil para **priorizar países y explicar decisiones** a negocio.

Uso recomendado

- 1) Filtrar mercados viables
- 2) Diseñar ranking y recomendador
- 3) Ajustar propuesta comercial por segmento

2. Qué explica el atractivo de un país

La señal más fuerte viene de conectividad, bienestar y variables de calidad de vida; el coste aislado no basta



Conectividad

Bienestar

Coste

Conclusión: la oferta con mejor encaje combina precio razonable con buena experiencia digital y calidad de vida percibida.

Lectura de negocio

Los drivers con correlación positiva más alta son broadband_speed_mbps y happiness_index. El mercado valora conectividad estable y calidad de vida.

Advertencia


Algunas variables ligadas a coste muestran relación negativa o limitada. Un destino barato no necesariamente será competitivo si pierde en experiencia o infraestructura.

Implicación


La propuesta de valor debe combinar affordability + internet + bienestar. Ese mix es más útil que vender solo "bajo coste".

3. Segmentación de ciudades

Se seleccionan 4 clusters: equilibrio entre interpretabilidad y calidad de separación



Silhouette 0.35



Cluster 1

2,179

budget hubs

Cluster 0

1,329

valor equilibrado

Cluster 2

1,081

premium

Cluster 3

153

coste medio / bajo
valor

Lectura ejecutiva

- 4 clusters permiten una segmentación útil para producto y go-to-market.
- El cluster más grande concentra opciones budget.
- El cluster premium es suficientemente grande para justificar una oferta diferenciada.
- Existe un pequeño grupo con coste no tan bajo y poder adquisitivo muy débil: conviene priorizarlo menos.

La segmentación sirve para empaquetar destinos, personalizar recomendaciones y evitar comparar ciudades con estructuras de coste muy distintas.

4. Perfil de los clusters y lectura de negocio

El heatmap ayuda a traducir cada grupo en una propuesta comercial o de recomendación

Cluster 1 Budget hubs

Coste mensual medio: 520 USD. Gran volumen y barrera de entrada baja. Útil para perfiles price-sensitive.

Cluster 2 Premium

Coste medio: 2,150 USD. Experiencia más cara, pero con mejores condiciones para usuarios de mayor presupuesto.

Cluster 0 Valor equilibrado

Coste medio: 1,279 USD. Mejor poder adquisitivo relativo. Buen segmento para recomendación principal.

Cluster 3 Bajo valor relativo

Coste medio: 871 USD con poder adquisitivo muy bajo. Debe tratarse con más cautela en rankings.

Decisión recomendada

Usar Cluster 0 como segmento "core", Cluster 1 para adquisición por precio, Cluster 2 como oferta premium y Cluster 3 como segmento de exclusión o revisión.

Perfil de Clusters (valores reales, color normalizado)



5. Predicción del digital nomad score

Se compararon varios modelos; ElasticNet ofrece el mejor equilibrio entre error, generalización y explicabilidad

Comparativa de modelos



ElasticNet

4.39

RMSE test

ElasticNet

0.79

R² test


Train/Test

estable

sin sobreajuste fuerte

Por qué gana ElasticNet

Aunque RandomForest empatara en RMSE test, ElasticNet mantiene mejor capacidad explicativa y una narrativa más clara para negocio. XGBoost muestra peor generalización en esta muestra.



Feature importance / pesos del modelo ganador

Lectura para stakeholders

El modelo final no solo predice; también explica. Esto facilita construir un scoring transparente y justificar recomendaciones frente a usuarios o partners.

6. Recomendaciones de negocio

Cómo convertir el análisis en decisiones, producto y comunicación

1. Construir un recomendador por segmento

Usar los 4 clusters para ordenar ciudades según budget, calidad y estilo de vida. Esto mejora la relevancia frente a un ranking único.

2. Priorizar países con buena conectividad + bienestar

Los países con mejor internet y happiness index deberían liderar campañas, partnerships y selección editorial.



3. Aplicar exclusiones inteligentes


Evitar sobreprometer destinos que son baratos pero ofrecen poco valor relativo. El cluster 3 debe vigilarse.

Idea fuerza: el mercado valora destinos accesibles, sí, pero sobre todo destinos viables para trabajar bien y vivir mejor.


Próximos pasos sugeridos

- Validar el scoring con feedback real de usuarios.
- Añadir variables dinámicas como visado, clima, comunidad o estacionalidad.
- Llevar el modelo a dashboard o API para consultas y ranking en tiempo real.







Distribución de variables




Distribución del target




Boxplot del target





XGBoostRegressor: Feature importance





Clúster 0 – Top 5 ciudades más representativas

	city_name	country_name	monthly_nomad_cost	local_purchasing_power	distancia_centroide
0	Lille	France	1315.315	2.036189	0.214
1	Reims	France	1227.840	1.902365	0.327
2	Laval	Canada	1272.355	2.148787	0.341
3	Lorient	France	1201.755	1.941028	0.344
4	Montevrain	France	1135.620	1.855806	0.374

Clúster 1 – Top 5 ciudades más representativas

	city_name	country_name	monthly_nomad_cost	local_purchasing_power	distancia_centroide
0	Santo Andre	Brazil	558.9800	1.113958	0.171
1	Sibiu	Romania	570.1050	1.103586	0.222
2	Campinas	Brazil	572.3000	1.049869	0.226
3	Tulcan	Ecuador	536.7775	1.117782	0.267
4	Targu-Mures	Romania	624.0000	1.143606	0.267

Clúster 2 – Top 5 ciudades más representativas


	city_name	country_name	monthly_nomad_cost	local_purchasing_power	distancia_centroide
0	Reykjavik	Iceland	2060.020	1.622746	0.355
1	Eden Prairie	United States	2144.370	1.756539	0.384
2	Arroyo Grande	United States	2015.965	1.868420	0.408
3	Evanston	United States	2155.415	1.762074	0.429
4	Baker	United States	2063.175	1.825667	0.438

Clúster 3 – Top 5 ciudades más representativas

	city_name	country_name	monthly_nomad_cost	local_purchasing_power	distancia_centroide
0	Vanadzor	Armenia	732.5600	0.310432	0.296
1	Beira	Mozambique	866.2825	0.301322	0.321
2	Tete	Mozambique	883.9575	0.295297	0.344
3	City of Paranaque	Philippines	789.1250	0.341049	0.544
4	Niamey	Niger	1012.0750	0.208986	0.689


Elastic Net

Feature importances



Random Forest

Feature importances



XGBoos

XGBoostRegressor: Feature importance

